

Informe Final: Proyecto Integrador Minería de Datos

Contexto y objetivo: El proyecto consistió en el análisis y el procesamiento del dataset *streaming_user_dirty*, el cuál registra datos de usuarios de una plataforma de streaming. El objetivo fue la transformación de datos crudos en información útil, identificando patrones sobre los consumos para poder mejorar la toma de decisiones basada en evidencias.

Dataset y calidad inicial: El dataset original contenía 8160 registros y 8 variables. La inspección inicial reveló varias anomalías:

- Datos faltantes y nulos: 193 nulos en tiempo de reproducción, 240 en género favorito y 320 en última fecha de inicio.
- Inconsistencias: Errores de escritura y múltiples datos duplicados.
- Datos ilógicos: Edades fuera de rango real con edades negativas y mayores de 100 años (la edad máxima puede llegar a ser real, pero tratándose de streaming es imposible), tiempos de reproducción negativos y de más de 30000 minutos y tickets de soporte mal registrados.

Decisiones de limpieza y preparación: Se ejecutó un pipeline estructurado (https://github.com/SantiagoBusta-dev/PI_Mineria_Datos_1/blob/main/logs/pipeline_log.csv)

- Imputación: Se utilizó la mediana para nulos en tiempo de reproducción y la moda para género favorito.
- Limpieza de fechas: Conversión a formatos *datetime*, eliminando 384 registros con fechas inválidas (ya que era un dato importante como para importar con moda, media o mediana)
- Consolidación: Se eliminaron 131 datos duplicados y se normalizó el texto mediante diccionarios, unificando planes, países y géneros.
- Filtros lógicos: Se filtró solo edades desde 0 a 90 años (ya que hay muchas plataformas con opciones de kids que son para niños chicos), tiempos de 0 a 5000 minutos (datos más realistas) y tickets de 0 a 20 (ya que es muy poco probable que haya datos mayores a 20 de reclamos al mes), logrando un dataset final de 7409 registros (90,8% de retención).

Hallazgos del análisis exploratorio (EDA): El análisis reveló que los tickets de soporte son bajos, no mayores de 5 por mes y no presentan correlación con la edad de los usuarios. Se identificó unos usuarios muy de

maratones, los cuáles cuentan con un rango de 2500 a 4200 minutos de reproducción, y obvio con un bajo volumen de reclamos.

Reclamos de dimensionalidad (PCA): Se pudo proyectar la complejidad de las variables en un estado bidimensional. Se observó una alta concentración de clientes promedio y un grupo secundario, evidenciando que el tipo de suscripción no es el factor determinante en el uso de la plataforma.

Conclusiones y limitaciones: EL proceso del proyecto nos permitió transformar los datos brutos en conocimiento trabajable, optimizando la calidad de la información para unos futuros análisis.

- Limitaciones: Solo se cuenta con los valores presentes en el dataset, por lo que no se puede contar con el contexto real ni los factores externos fuera de los datos registrados en la plataforma (ejemplo, en el tiempo de reproducción, puede verse modificado por el uso de la cuenta de un usuario en varios dispositivos, lo cuál dará más tiempo de reproducción y no significa que sea solo de un usuario).

Enlace de aplicación de Streamlit: <https://pimineriadatos1-kjpk4kvynnmh4hmnjdqcis.streamlit.app/>